



**XML** |

# XML

- XML = *eXtensible Markup Language* : langage de balisage extensible.
- XML est un langage pour structurer des contenus et définir une classe d'objets de données, par exemple:
  - ✓ un dessin vectoriel (SVG), une page Web (XHTML), un flux (RSS)...
- Le langage est basé sur le concept de balisage des données.
- Un document XML:
  - ✓ contient des déclarations, éléments, commentaires, définition de caractères spéciaux et instructions (facultatives) de traitement
  - ✓ c'est un arbre: il doit avoir une racine et les éléments doivent s'imbriquer proprement
- Plus simple que SGML ( langage de balisage généralisé normalisé, iso), plus complexe mais moins confus et plus performant que HTML
- Recommandation officielle du W3C (The World Wide Web Consortium) depuis le 10 février 1998
- Idéal pour l'échange de données semi-structurées
- Utilisable entre machines

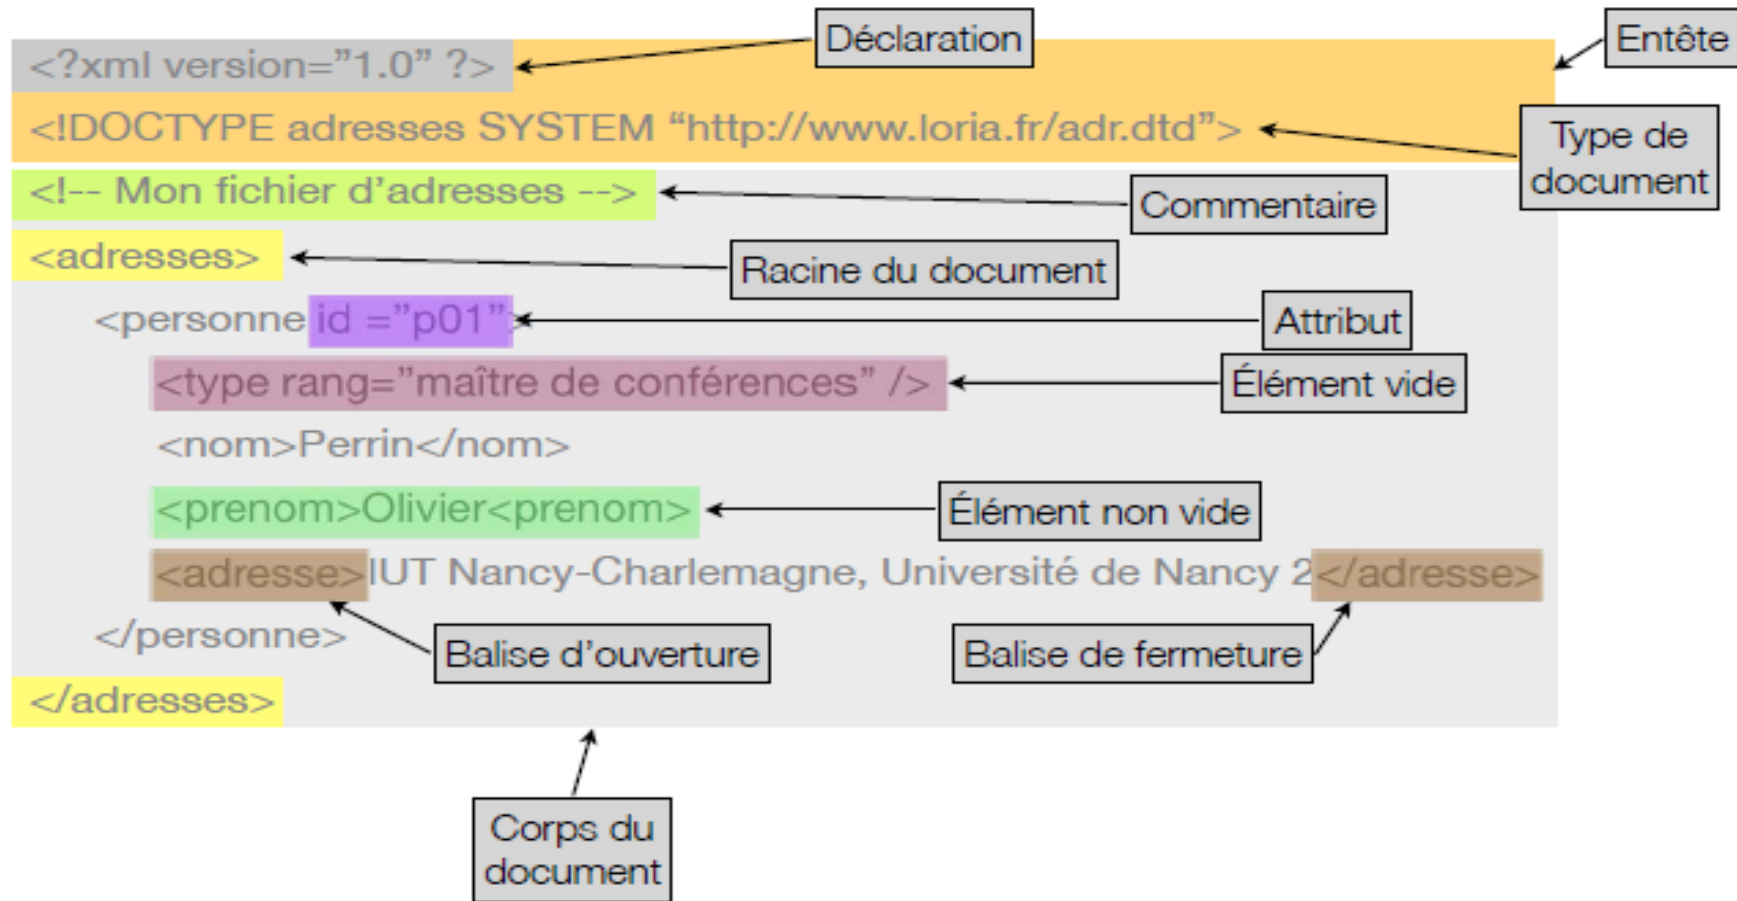
# XML (2)

- XML, c'est donc...
  - ✓ un méta-langage universel pour structurer les données...
  - ✓ qui permet aux utilisateurs de délivrer du contenu...
  - ✓ depuis les applications à d'autres applications (browsers par exemple)
- XML promet de standardiser la manière dont l'information est :
  - ✓ échangée (XML)
  - ✓ personnalisée/présentée (XSL/CSS)
  - ✓ recherchée (XPath/XSLT/XQuery)
  - ✓ sécurisée (Encryption, Signature)
  - ✓ liée (XLink)

# XML (3)

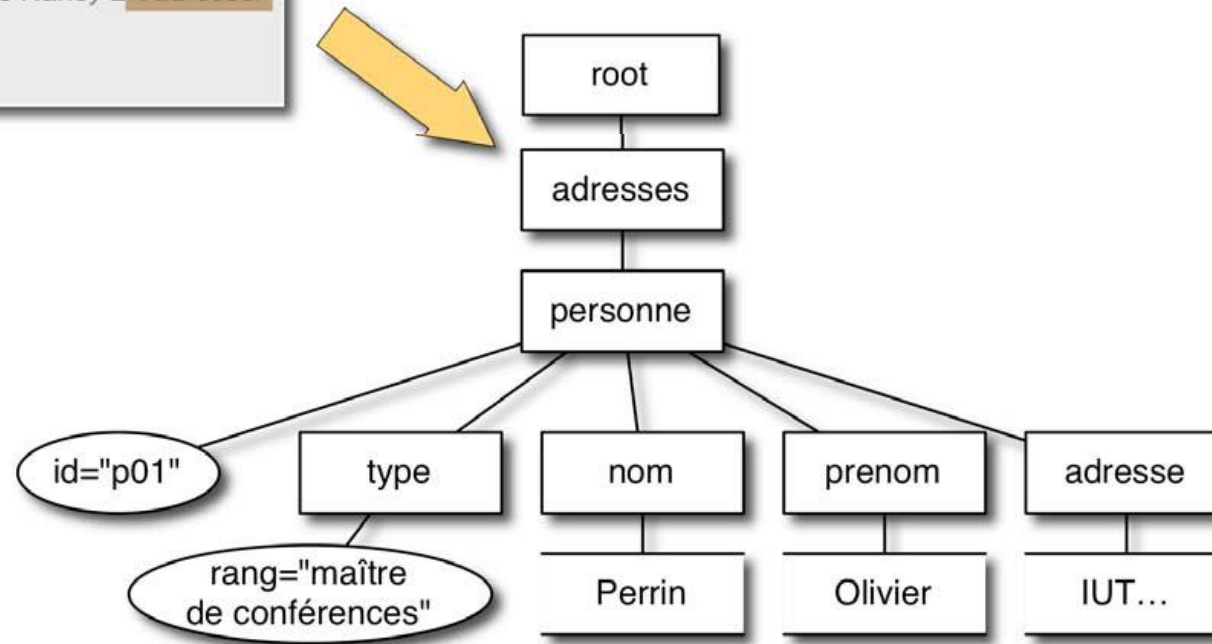
- Balise (ou tag ou label)
  - ✓ marque de début et fin permettant de repérer un élément de données (textuel)
  - ✓ forme: <balise> de début, </balise> de fin
  - ✓ les balises indiquent la signification des sections marquées
- Élément de données
  - ✓ texte encadré par une balise de début et une de fin
  - ✓ les éléments de données peuvent être imbriqués
- Attribut
  - ✓ couple nom="valeur" qualifiant une balise
  - ✓ <producteur no="160017" region="Bourgogne"/>
- Les utilisateurs définissent leurs propres balises
- Il est possible d'imposer une grammaire spécifique (DTD, Schéma)

# XML: UN EXEMPLE



# XML: FORMAT INTERNE

```
<?xml version="1.0" ?>  
<!DOCTYPE addresses SYSTEM "http://www.loria.fr/adr.dtd">  
<!-- Mon fichier d'adresses -->  
<addresses>  
  <personne id="p01">  
    <type rang="maître de conférences" />  
    <nom>Perrin</nom>  
    <prenom>Olivier</prenom>  
    <adresse>IUT Nancy-Charlemagne, Université de Nancy 2</adresse>  
  </personne>  
</addresses>
```



# POURQUOI XML ?

- Définir vos propres langages d'échange
  - ✓ commande, facture, bordereau de livraison, etc.
- Modéliser des données et des messages
  - ✓ *Document Type Definition (DTD)*
  - ✓ types et éléments agrégés (*XML Schema Definition*)
  - ✓ passerelle avec *Unified Modelling Language (UML)*
- Publier des informations
  - ✓ indépendante du format
  - ✓ mise en forme avec CSS et XSL
  - ✓ présentation possible en XHTML, PDF, WML,...
- Archiver des données
  - ✓ auto-description des archives

# COMPARAISON DONNÉES/DOCUMENTS

## ➤ Approche «Donnée»

- structuration forte et simple
- compatibilité SGBDR existants
- mise à jour en place
- intégrité sémantique
- indexation exacte
- adapté au transactionnel et décisionnel
- performances «moyenne» à «fort» pour une volumétrie «moyenne »

## ➤ Approche «Document»

- structuration faible et complexe
- systèmes documentaires spécialisés
- gestion de versions
- recherche textuelle
- indexation approchée
- accès type moteur de recherche
- performances «moyenne» pour une volumétrie «forte»



# AVANTAGES DE XML

- Une technologie structurante
- Clarifie toutes les interfaces d'échange
- Transversale à l'entreprise
  - ✓ échanges de données
  - ✓ Bureautique
  - ✓ GED
  - ✓ sites Web
  - ✓ EDI
  - ✓ bases de données
  - ✓ intégration e-business
  - ✓ ...
- Un choix stratégique de direction
  - ✓ ne pas rester isolé

# FAIBLESSES DE XML

- Une syntaxe verbeuse
- Un méta-langage, mais de nombreux langages
- Coûteux en CPU
  - ✓ Analyse
- Coûteux en mémoire
  - ✓ instanciation

# XML ET BD

- Intégration des données et méta-données
- Standard d'échange de données universel
- Les BD ne peuvent rester indifférentes :
  - ✓ nécessité de stocker les documents XML
  - ✓ nécessité de pouvoir interroger ces documents
  - ✓ évolution ou révolution ?
- Quel modèle de données ?
- Quel langage d'interrogation ?
- Quelle intégration avec l'existant ?



# MODÈLES DE DONNÉES

# DOCUMENT XML

- Un document XML peut être associé à:
  - ✓ une DTD ou un schéma pour décrire la structure du document XML
  - ✓ une feuille de style pour présenter les données
  - ✓ DTD ou/et schéma permettent de définir son propre langage basé sur XML
  - ✓ vocabulaire (balises)
  - ✓ grammaire (imbrications)
- Deux types de documents
  - ✓ *well-formed document*
  - ✓ *valid document*

# DOCUMENT BIEN FORMÉ (*WELL-FORMED*)

- Commence par une déclaration XML (attribut version obligatoire) avec possibilité de choisir un encodage (le défaut est utf-8):

```
<?xml version="1.0" encoding="ISO-8859-1"?>
```

- Structure hiérarchique:

- ✓ les balises d'ouverture et de fermeture doivent apparaître et correspondre
- ✓ pas de croisements de type `<i>...<b>...</i> .... </b>`
- ✓ sensible à la casse: "LI" n'est pas égal à "li" par exemple
- ✓ balises "EMPTY" utilisent la syntaxe XML "auto-fermante": `<br/>`
- ✓ les valeurs d'attributs sont quotés: `<a href="http://www.foo.fr/xml.html">`
- ✓ un seul élément racine (root):
  - l'élément root ne peut apparaître qu'une fois et ne doit pas apparaître dans un autre élément

- Caractères spéciaux (!!): `<`, `&`, `>`, `"`, `'`

- ✓ utilisez `&lt;`, `&amp;`, `&gt;`, `&quot;`, `&apos;` à la place dans un texte !
- ✓ les espaces sont préservés

# DOCUMENT VALIDE (*VALID*)

- Un document “valide” doit être:
  - ✓ “well-formed” (formé correctement)
  - ✓ être associé à une DTD (ou une autre grammaire)
  - ✓ et être conforme à cette DTD ou une grammaire